王 潇

19974741419 | wx191038@gmail.com | 25岁
求职意向：大模型算法工程师 | Jason-wx
(Post-Training / MoE / Safety Alignment / Interpretability / Evaluation / Data)



教育经历

东北大学（985） 硕士 人工智能 2024.9 - 2027.6

- ***From Parameter Dynamics to Risk Scoring: Quantifying Sample-Level Safety Degradation in LLM Fine-tuning*** (ICML 2026, CCF-A, arxiv/2605.04572, 独立一作)
- ***Towards Architectural-Level Safety Control: Relocating Hazardous Knowledge into Removable Experts in Mixture-of-Experts Models*** （TechReport, Shanghai-AILab, arxiv/2610.25791 , 核心贡献者）

南昌航空大学 本科 数据科学与大数据技术 2020.9 - 2024.6

科研|项目经历

LLMs微调安全退化机理与训练数据风险量化（ICML2026） FinetuningRisk-Quantify

项目描述： 大语言模型在后训练阶段即使使用无害数据微调，也会导致安全对齐能力退化，且此类样本能绕过传统毒性分类器。本项目从参数动力学视角对该现象做了可解释性分析，并提出 SQSD 方法，在微调开始前以单样本粒度输出连续风险分数，可直接作为微调数据的准入过滤器。**[能力下降现象可解释性分析，训练数据微调风险治理]**

项目内容:

- **安全退化的动力学机制**：基于 Task Vector，用 SFT 与 DPO 分别构造危险 / 安全参数方向，并经 Vector Steering 验证其语义有效性；追踪微调全程的参数轨迹，发现参数持续沿危险方向累积漂移而安全方向投影近零，呈“先漂移、后崩塌”两阶段模式。正交化剔除危险方向分量后 ASR 由 15.09% 降至 0.91%， **无需训练恢复安全性能。**
- **数据训练风险量化方法 SQSD：**单步 LoRA 梯度刻画样本诱导的参数更新，取其在危险与安全方向上的投影**差**作为风险分数；设计 Module-wise Normalization 消除短回复偏差；通过一阶泰勒近似建立参数位移与模型输出偏好之间的理论联系。
- **效果验证：**在 3 模型 * 2 数据集 * 2 危险方向共 12 组配置上，风险由高**ASR 单调递减 10/12（最强基线仅 1/6）**，高低风险子集 ASR 差均值 **49.86% ; 仅过滤 10% 的高风险数据后 ASR 从 30.18% 下降到 4%。**
- **工程可用性**：风险分数可跨参数规模（8->32B）、跨模型架构（Llama | Qwen）、跨微调方式（LoRA->全参），全部保持单调，支持“小模型打分、大模型部署”。

基于参数 Steering 的大模型安全关键参数区域识别 Parameter-Steering

项目描述：将 Beaver-Danger LoRA 更新视为可控参数干预，在 Qwen3-8B 上沿注入强度、模块类型、projection 与网络深度做系统扫描，绘制安全性随干扰强度变化的剂量—响应曲线，定位承载安全对齐的关键参数区域。

关键结论:（1）**危险方向连续可逆且非线性**，注入强度由 0 增至 2 时 ASR 从 0.73% 升至 68.55%，反向至 s=-1 降至 0.18%；（2）**中层 14–29 层为主导区域**，仅激活即恢复完整方向约 74% 的 ASR 增量（3）**MLP 强于 Attention**，o_proj、up_proj、down_proj 为最敏感参数群。

实习经历

上海人工智能实验室 安全基模中心 2026.6 -

- **内生安全 MOE 架构 [REX-MoE]：**在一个已经具备双重知识（安全知识 + 有害知识）的预训练 MoE 模型上，通过引入新增的 Harmful Experts 并结合路由和梯度掩码机制进行持续预训练，实现 **(1)富集 (Enrichment)**：将有害知识从原有专家中遗忘，并集中吸入到新增的 Harmful Experts 中；**(2)剔除 (Ablation)**：在推理阶段安全地切除 Harmful Experts，实现有害能力的根除，同时保持通用能力。**Intern-Preview(83.7%,85.15%)->Enriched(82.5%,83.7%)->Ablated(29.1%,81.8%),** WMDP-Bio 随机、MMLU 保持（实现了危险知识的精准去除）。
- **面向 MoE 架构的大模型遗忘学习框架 [MoE-Unlearn]：**将 **10 种主流 Unlearning** 算法（GD | GA | RMU | PDU 等）统一适配至 MoE 架构模型。框架支持 **Qwen3.*、InternS2、Gemma4** 三类模型族，兼容 **Megatron 与 DeepSpeed** 两种分布式后端，训练参数支持 router / expert / all 三级区域，支持基础 Chunk 和 Xtuner 的 CPT 数据处理格式。实现了 Qwen3.5-35B-A3B | Gemma4-26B-A4B | InternS2-Preview 在 10 种算法上的 改进训练与优化。

之江实验室 科学数据枢纽中心 2026.3 - 2026.6

科学推理后训练数据制备 Pipeline： 构建 SFT 蒸馏 + RL 优化 的多阶段训练流程；SFT 阶段通过蒸馏和 n-gram 实现数据生产和多样性筛选， RL 阶段通过 SciRubric-Guided Reward 和 Dynamic Difficulty Curriculum，提升开放式科学推理任务的训练稳定性。

- **数据制备：**参与科学推理数据构建，完成 **Data Distillation、4-gram Diversity Selection、Rubric Reward Design 与 Difficulty Annotation**，提升训练数据的推理模式覆盖和开放式问题可评价性。
- **训练优化：** 参与 SFT 训练与 Dynamic Difficulty Curriculum 设计，基于样本难度和模型掌握情况动态调整 RL 训练数据分布，在线数据只占全量数据的 15% 达到全量数据性能。训练 Qwen3-4B-Base 后**在 GPQA-Diamond（63.1%） 和 MMLU-Pro （75.1%）**(超越 QwQ-32B 和 Qwen3-4B thinking，与 o1-mini 和 Qwen3-4B-thinking-2507 持平)。